

## Métricas ponto a ponto (continuação)

### Dados do tipo monóide

Considere-se o espaço de atributos  $\mathcal{A} = A \times A \times A \times \dots \times A = A^l$ . onde  $A = \{\epsilon, a, b, c, \dots, z\}$ .

Para trabalhar este tipo de dados, vamos considerar o caso em que  $l = 5$ . Ou seja consideramos palavras até 5 letras.

Uma função dissemelhaça poderá ser,

$d(x, y)$  = número de letras de  $x$  que são diferentes de  $x'$ .

**Exemplo 16:** Mostrar que é uma dissemelhança não simétrica, não está normalizada, e não verifica difinitness.

Usar definição de função de dissemelhança e arranjar contra exemplo que mostre que  $d(x, y) \neq d(y, x)$ . Mostrar que pode ter valores fora de  $[0, 1]$  e que existem casos que  $d(x, y) = 0$  e  $x \neq y$ .

# Métricas em Machine Learning

Uma outra função de semelhança poderá ser,

$$s(x, y) = \frac{1}{5}(s1(x, y) + s2(x, y) + s3(x, y) + s4(x, y) + s5(x, y))$$

onde,

$$s_i(x, y) = \begin{cases} 1 & \text{se } x_i = y_i \\ 0 & \text{se } x_i \neq y_i \end{cases}$$

**Exemplo 17:** Verificar se é uma semelhança simétrica, se está normalizada, e se verifica difinitness.

**Exemplo 18:** Calcule  $s('aula', 'aulas')$ ,  $s('aulas', 'aula')$ .

# Métricas em Machine Learning

## Métricas com dados Reais

$\mathcal{A} = \mathbb{R}^I$ ,  $x = (x_1, x_2, \dots, x_I) \in \mathcal{A}$ , é elemento genérico que pode ser evento  $e^n$  duma base de dados  $D$ .

### Métrica de Minkowski :

Seja  $r > 0$ . A Métrica de Minkowski é:

$$d_r(x, y) = \left( \sum_{i=1}^I |x_i - y_i|^r \right)^{1/r}.$$

De acordo com os valores de  $r$  obtêm-se diferentes métricas. Se  $r \in ]0, 1[$  não se verifica a desigualdade triangular.

**Exemplo 19:** Considere  $r = 1/4$ ;  $x = (0, 0)$ ,  $y = (0, 1)$  e  $z = (1, 1)$ . Verifique se a métrica em causa verifica a desigualdade triangular.

$$d_{\frac{1}{4}}(x, y) = 1; \quad d_{\frac{1}{4}}(y, z) = 1; \quad d_{\frac{1}{4}}(x, z) = 16;$$

Logo,  $d_{\frac{1}{4}}(x, z) \leq d_{\frac{1}{4}}(x, y) + d_{\frac{1}{4}}(y, z)$  é falso.

# Métricas em Machine Learning

## Métricas com dados Reais

**Distância de Manhattan:** Fazer  $r = 1$ . Obtém-se,

$$d_1(x, y) = \sum_{i=1}^I |x_i - y_i|$$

**Exemplo 20:**  $x, y \in \mathbb{R}^2$ . Seja  $x = (1, 1)$  e  $y = (2, 2)$ . Calcule a distância de Manhattan entre  $x$  e  $y$ .

$$d_1(x, y) = |1 - 2| + |1 - 2| = 2.$$

## Distância de Euclidiana:

Fazer  $r = 2$ . Obtém-se,

$$d_2(x, y) = \sqrt{\sum_{i=1}^I |x_i - y_i|^2}.$$

**Exemplo 21:** Mostrar que a métrica Euclidiana é uma distância.

# Métricas em Machine Learning

É necessário mostrar que,

- a)  $d_2(x, y) \geq 0$ . (positividade)
- b)  $d_2(x, y) = d_2(y, x)$ . (simetria)
- c)  $d_2(x, y) = 0 \equiv x = y$ . (definitness)
- d)  $d_2(x, z) \leq d_2(x, y) + d_2(y, z)$  (desigualdade triangular).

Também se consegue provar que,

- a) Compatibilidade com a adição -  $d_2(0, x) = \sqrt{x_1^2 + x_2^2}$  e  $d_2(y, x + y) = \sqrt{x_1^2 + x_2^2}$ .
- b) Compatibilidade com a multiplicação por constante  $\lambda$ ,  $d_2(\lambda x, \lambda y) = |\lambda| d_2(x, y)$ .

# Métricas em Machine Learning

**Distância de Chebyshev:** Fazer  $r \rightarrow \infty$ . Obtém-se,

$$d_{\infty}(x, y) = \max |x_i - y_i| \text{ com } i = 1, \dots, l.$$

**Exemplo 22:**

Sejam  $x, y \in \mathbb{R}^2$ , onde  $x = (1, 1)$  e  $y = (2, 3)$ . Calcule  $d_{\infty}(x, y)$ .

Solução : 2.

**Dissemelhaça de Rook :** Considerando  $\mathcal{A} = \mathbb{R}^2$ , define-se como:

$$d_{Rook}(x, y) = \begin{cases} |x_2 - y_2| & \text{se } x_1 = y_1 \\ |x_1 - y_1| & \text{se } x_2 = y_2 \\ +\infty & \text{se noutros casos} \end{cases}$$

**Exemplo 23:** Mostre que  $d_{Rook}$  não verifica a desigualdade triangular.

## 3. Métricas para sub conjuntos (subset metrics)

- A ideia é usar métricas ponto a ponto, para definir métricas para sub conjuntos.
- O cálculo do representante dum conjunto  $C$  pode ser importante. Este vai depender da métrica usada + operações algébricas possíveis no espaço dos atributos.

### Dados reais - representante dum conjunto

- $\mathcal{A} = \mathbb{R}$ ,  $D = \{x^n : n = 1, \dots, N\}$  onde  $x^n \in \mathbb{R}$ .
- Vamos assumir que os dados são ordenados.
- Para determinar o representante  $m \in \mathcal{A}$  dum conjunto  $C$  vamos definir a funcional,

$$E(m; C) = \sum_{n=1}^N (d_2(m, x^n))^2 = \sum_{n=1}^N (x^n - m)^2.$$

se usarmos a métrica Euclidiana.

# Métricas em Machine Learning

ou seja,

$$E(m; C) = (d_2(m, x^1))^2 + (d_2(m, x^2))^2 + \dots + (d_2(m, x^N))^2$$

O objetivo é determinar  $m$  que minimiza  $E$ ,

$$\bar{m} = \arg \min_m E(m; C).$$

Usando uma métrica Euclidiana vem,

$$E(m; C) = (x^1 - m)^2 + (x^2 - m)^2 + \dots + (x^N - m)^2$$

Derivando e igualando a 0 vem,

$$-2(x^1 - m) - 2(x^2 - m) - \dots - 2(x^N - m) = 0.$$

Resolvendo em ordem a  $m$ ,

$$m = \frac{1}{N} \sum_{i=1}^N x^i,$$

ou seja, o representante de  $C$  é o valor médio dos valores de  $C$ .




# Métricas em Machine Learning

Se a métrica usada for a de Manhattan, temos,

$$E(m, C) = \sum_{n=1}^N |m - x^n|.$$

Notar que a funcional não é derivável.




Notar que à esquerda de  $x^n$  é estritamente decrescente com declive -1, e à direita de  $x^n$  é estritamente crescente com declive 1. Podemos definir,

$$E'(m; C) = \sum_{n=1}^N \text{sign}(m - x^n), \text{ com } m \neq x^1, x^2, \dots, x^N, \text{ onde } \text{sign} \text{ é } -1 \text{ ou } 1.$$

# Métricas em Machine Learning

**Exemplo 24:** Seja  $C = \{x^1, x^2, x^3, x^4\}$  onde  $x^n \in \mathbb{R}$ . Calcule representante de  $C$  usando a métrica de Manhattan.

Pretende-se então ver qual o valor de  $m$  para o qual a funcional é mínima.



$$E'(m_1; C) = -4, E'(m_2; C) = -2, E'(m_3; C) = 0, E'(m_4; C) = 2, E'(m_5; C) = 4.$$

# Métricas em Machine Learning

Assim, se temos  $C = \{x^1, x^2, \dots, x^N\}$ , com  $x^n \in \mathbb{R}$  podemos definir como **representantes** de  $C$ , o valor médio com métrica Euclidana. Poderá ser interpretado como mediana se usamos a métrica de Manhattan. (média mto. diferente de mediana  $\rightarrow$  outliers)

## Métricas entre subconjuntos (Inter cluster metrics)

Existem na literatura várias métricas entre dois sub conjuntos (clusters). Apresentamos algumas, e denominamos de  $dd$ .


- 1) Sejam  $m$  e  $m'$  os representantes de  $C$  e  $C'$ , então  $dd(C, C') = d(m, m')$ . Neste caso estamos a usar uma métrica ponto a ponto entre os representantes dos clusters.
- 2)  $dd(C, C') = \min d(x, x')$ ,  $x \in C$ ,  $x' \in C'$ . Chamada de **Single Linkage**, calcula a menor distância entre pontos de  $C$  e pontos de  $C'$ .
- 3)  $dd(C, C') = \max d(x, x')$ ,  $x \in C$ ,  $x' \in C'$ . Chamada de **Complete Linkage**, calcula a maior distância entre pontos de  $C$  e pontos de  $C'$ .

# Métricas em Machine Learning

$$4) dd(C, C') = \frac{1}{|C| \cdot |C'|} \sum_{x \in C, x' \in C'} d(x, x'), \quad x \in C, x' \in C'. \text{ Chamada de}$$

**Average**, calcula a média das distâncias entre pontos de  $C$  e pontos de  $C'$ .

## Contróide versus Medóide



Centróide é o 'centro de massa' ; Medóide pertence ao conjunto.

# Métricas em Machine Learning

**Definição :**  $\bar{m} \in \mathcal{A}$  é um **centróide** de  $C$  se  $\forall x \in \mathcal{A} \ E(x; C) \geq E(\bar{m}; C)$ , escreve-se,

$$\bar{m} = \arg \min_{x \in \mathcal{A}} E(x; C)$$

**Definição :**  $\bar{m} \in C$  é um **medóide** de  $C$  se  $\forall x \in C \ E(x; C) \geq E(\bar{m}; C)$ , escreve-se,

$$\bar{m} = \arg \min_{x \in C} E(x; C)$$

Notar que no segundo caso  $x \in C$ .

# Métricas em Machine Learning

**Dados em  $\mathbb{R}^I$  - representante do tipo centróide**

$\mathcal{A} = \mathbb{R}^I$ ,  $C = \{x^n : n = 1, \dots, N\}$  onde  $x_i^n \in \mathbb{R}$  representa o atributo  $i = 1, \dots, I$  do evento  $n = 1, \dots, N$ .

Neste caso, definimos a função custo,

$$f(m) = \sum_{n=1}^N d(m, x^n) \quad , \text{ onde } ,$$

$$d(m, x^n) = \sum_{i=1}^I (m_i - x_i^n)^2 \quad (\text{se } d \text{ for distância Euclidiana}) .$$

Assim  $f$  representa a soma para todos os eventos de  $C$  da distância do representante de  $C$  que é  $m$  ao elemento de  $x_i^n \in C$ .

Como os elementos de  $C$  têm  $I$  componentes, usando a **distância Euclidiana**, fazemos a soma para todas as componentes de  $(m_i - x_i^n)^2$ .

# Métricas em Machine Learning

Assim, podemos escrever a função custo,

$$f(m) = \sum_{n=1}^N \sum_{i=1}^I (m_i - x_i^n)^2 = \sum_{i=1}^I \sum_{n=1}^N (m_i - x_i^n)^2.$$

Se definirmos,  $f_i(m_i) = \sum_{n=1}^N (m_i - x_i^n)^2$ , para encontrar o representante de  $C$ , temos que encontrar  $m \in \mathbb{R}^I$  que minimiza  $f$ , que é o mesmo que **encontrar os  $m_i \in \mathbb{R}$  que minimizam  $f_i$ .**

Assim, para cada componente temos o problema de otimização semelhante ao caso 1D, que vimos ter como solução, o valor médio. Podemos então escrever,

$$\bar{m} = \frac{1}{N} \begin{bmatrix} \sum_{n=1}^N x_1^n \\ \sum_{n=1}^N x_2^n \\ \dots \\ \sum_{n=1}^N x_I^n \end{bmatrix}$$

$m$  que é o representante de  $C$  é um centróide (normalmente não vai dar um elemento de  $C$ ).

# Métricas em Machine Learning

Se optarmos por usar a **Métrica de Manhattan**, temos que a função custo é agora,

$$f(m) = \sum_{n=1}^N \sum_{i=1}^I |m_i - x_i^n| = \sum_{i=1}^I \sum_{n=1}^N |m_i - x_i^n|.$$

Se definirmos,  $f_i(m_i) = \sum_{n=1}^N |m_i - x_i^n|$ , para encontrar o representante de  $C$ , temos que encontrar  $m \in \mathbb{R}^I$  que minimiza  $f$ , que é o mesmo que **encontrar os  $m_i \in \mathbb{R}$  que minimizam  $f_i$** . Vimos para o caso 1D que o representante é a mediana. Assim, neste caso, escrevemos,

$$\bar{m} = \begin{bmatrix} \bar{m}_1 \\ \bar{m}_2 \\ \dots \\ \bar{m}_N \end{bmatrix}$$

onde  $\bar{m}_i$  é a mediana dos  $x_i^n$ .



# Métricas em Machine Learning

**Exemplo 24 :** Considere  $C = \{x^1, x^2, x^3, x^4, x^5\}$  onde  $x^1 = (0, 0)^T$ ,  $x^2 = (2, 1)^T$  e  $x^3 = (2, 4)^T$ ,  $x^4 = (1, -2)^T$  e  $x^5 = (-2, 4)^T$ .

- a) Calcule o representante de  $C$  usando a métrica Euclidiana.
- b) Calcule o representante de  $C$  usando a métrica de Manhattan.

## Dados em $\mathbb{R}^I$ - representante do tipo medóide

O raciocínio é o mesmo. temos que minimizar uma função custo  $f(m)$ , mas acrescentamos a restrição de que esse representante tem que ser membro do conjunto  $C$ . É computacionalmente mais pesado.

Assim, pretende-se minimizar a função custo,

$$f(m) = \sum_{n=1}^N d(m, x^n)$$

com a restrição de que  $m \in C$ . Ou seja,

$$\bar{m} = \arg \min_{x \in C} f(m)$$

# Métricas em Machine Learning

**Exemplo 25 :** Considere  $C = \{x^1, x^2, x^3, x^4, x^5\}$  onde  $x^1 = (0, 0)^T$ ,  $x^2 = (2, 1)^T$  e  $x^3 = (2, 4)^T$ ,  $x^4 = (1, -2)^T$  e  $x^5 = (-3, 1)^T$ .

Calcule o representante de  $C$  do tipo medóide, usando a métrica de Manhattan.