

## Dados nominativos - Representante

Quando lidamos com dados categóricos, não é óbvia a escolha dum representante. Uma das vias passa por usar as frequências que quantificam a probabilidade de **match** dos elementos mais frequentes.

### Um exemplo:

Seja  $\mathcal{A} = A_1 \times A_2 \times \dots \times A_I$  o espaço admissível dos atributos, onde  $A_i = \{a_{i,1}, a_{i,2}, \dots, a_{i,J_i}\}$  é uma lista de  $J_i$  elementos que caracterizam  $A_i$ .

Podemos definir uma função de semelhança entre  $x, y \in \mathcal{A}$ ,

$$s_i(x, y) = \begin{cases} 1 & \text{se } x_i = y_i \\ 0 & \text{se } x_i \neq y_i \end{cases}$$

que diz se o atributo  $i$  do elemento  $x$  é ou não igual ao atributo  $i$  do elemento  $y$ .  
E a função de semelhança global,

$$s(x, y) = \sum_{i=1}^I s_i(x, y).$$

# Métricas em Machine Learning

Seja  $D = \{x^1, x^2, \dots, x^N\}$  um conjunto de dados, para o qual procuramos um representante. Defina-se uma funcional  $S$  que avalie o grau de semelhança entre o seu representante  $m$  e os seus dados  $x^n$ .

$$S(m; D) = \sum_{n=1}^N s(m, x^n).$$

O melhor candidato a representante de  $D$  tem que maximizar  $S$ .

$$m = \arg \max_{m \in \mathcal{A}} S(m; D).$$

Ou seja, o representante de  $D$  vai maximizar a funcional,

$$S(m; D) = \sum_{n=1}^N \sum_{i=1}^I s_i(m, x^n) = \sum_{i=1}^I \sum_{n=1}^N s_i(m, x^n) = \sum_{i=1}^I S_i(m; D)$$

que corresponde a calcular o máximo valor de semelhança para cada  $S_i$  (maximizar semelhança entre  $m_i$  e as componentes  $i$  de todos os elementos de  $D$ ).

# Métricas em Machine Learning

Seja  $N_{i,j}$  o número de elementos de  $D$  tal que  $x_i^n = a_{i,j}$ , então,

$$S_i(a_{i,j}; D) = N_{i,j}.$$

O conjunto  $D$  tem número finito de elementos  $\rightarrow$  existe um máximo (não necessariamente único) a que chamamos  $\overline{m}_i$ .

Notar que  $\overline{m}_i$  é o elemento da categoria  $A_i$  que ocorre mais vezes (**moda**).

Fazendo o mesmo para todas as componentes, obtém-se o representante de  $D$ ,

$$\overline{m} = (\overline{m}_1, \overline{m}_2, \dots, \overline{m}_I)$$

.

Trata-se de um representante do tipo centróide já que  $\overline{m}$  não pertence a  $D$ .

# Métricas em Machine Learning

## Exemplo 26 :

Considere  $\mathcal{A} = A_1 \times A_2 \times A_3$  onde  $A_1 = \{boreal, temperado, tropical\}$ ,  $A_2 = \{F, T\}$  e  $A_3 = \{branco, amarelo, laranja, vermelho\}$ . Considere ainda o conjunto  $D$  definido pela tabela,

n	A1	A2	A3
1	boreal	F	amarelo
2	tropical	T	amarelo
3	tropical	F	laranja
4	temperado	F	amarelo
5	boreal	T	branco
6	boreal	T	branco

Calcule o representante, usando a métrica definida atrás.

## Clustering

### Notações :

Considere-se o espaço dos atributos  $\mathcal{A} = A_1 \times A_2 \times \dots \times A_I$ .

$x^n = (x_1^n, x_2^n, \dots, x_I^n)$  representa o evento  $n$  da base de dados  
 $D = \{x^n \in \mathcal{A} : n = 1, \dots, N\}$ ,


**Definição :**  $\mathcal{P}$  é uma K-partição de  $D$  se,

$\mathcal{P} = \{C^1, C^2, \dots, C^K\}$  onde,

- a)  $C^K \subseteq D$  com  $C^k \neq \emptyset$ ;
- b)  $C^K \cap C^L = \emptyset$  para  $K \neq L$ ;
- c)  $\bigcup_{k=1}^K C^k = D$ .

Uma partição de um conjunto  $D$  é uma família de conjuntos composta por subconjuntos não vazios de  $D$ , disjuntos 2 a 2 e cuja união é  $D$ .

# Métricas em Machine Learning



Uma a partição de  $D$  representada na figura acima poderá ser  $\mathcal{P} = \{C^1, C^2, C^3\}$ .

De seguida vamos apresentar um algoritmo do tipo **partitional clustering**:

- 1) Devemos analisar os dados e escolher métricas apropriadas;
- 2) Escolher técnica para determinar representante  $\rightarrow$  escolher função custo e minimiza-la;
- 3) Escolher o tipo de algoritmo de Partitional Clustering (vamos falar de 2 : tipo Lloyd e Hierarchical Clustering).

## Mappings

Seja  $D = \{x^n : n = 1, \dots, N\}$  uma base de dados com elementos  $x^n \in \mathcal{A}$ .

Seja  $\mathcal{P} = \{C^1, C^2, \dots, C^K\}$  uma partição de  $D$ .


O mapa de representantes de  $\mathcal{P} = \{C^1, C^2, \dots, C^K\}$  faz a associação  $m^k = \text{Representante}(C^k)$ .

O conjunto dos representantes é dado por,


$$\hat{\mathcal{M}}(\mathcal{P}) = \{\text{Representante}(C^1), \text{Representante}(C^2), \dots, \text{Representante}(C^K)\}$$

que é uma função de mapping, que tem por input uma partição  $\mathcal{P}$  e tem por output um conjunto de representantes.

# Métricas em Machine Learning



**P mapping:** dados um conjunto de representantes  $\mathcal{M}$  e o conjunto  $D$  vai construir novos clusters obtendo uma nova partição de  $D$ .





## Algoritmo do tipo LLoyd

- Para um valor de  $K$  (número de clusters), e a partir dos dados em  $D$ , gera  $K$  clusters convexos;
- Converge num número finito de iterações;
- O número de iterações pode ser grande;
- A partição final depende da condição inicial -  $\mathcal{M}(0)$ ;
- Não há garantias que a partição obtida seja a melhor. (a função a minimizar pode admitir mínimos locais)
- para dados reais, usando a métrica Euclidiana é uma implementação do algoritmo **K-means**.

## Algoritmo de LLoyd

$K \leftarrow \text{ler}$

$\mathcal{M}(0) = \{m^1(0), m^2(0), \dots, m^K(0)\}$

CP=0; t=1

While  $\neg \text{CP}$

$\mathcal{P}(t) = \hat{\mathcal{P}}(\mathcal{M}(t-1))$

$\mathcal{M}(t) = \hat{\mathcal{M}}(\mathcal{P}(t))$

CP=condicao de paragem( $\mathcal{M}(t), \mathcal{M}(t-1)$ )

t=t+1

End While

## Exemplo 27:

Aplicar o algoritmo de Lloyd com:

$$(\mathcal{A}, d, m) = (\mathbb{R}^2, \textit{Euclidiana}, \textit{centroide}) ;$$

$$K = 2;$$

$$D = \{(1, 1)^T, (1, 2)^T, (1, 3)^T, (2, 1)^T, (2, 4)^T, (3, 4)^T, (4, 4)^T\}.$$